

存储层级感知的大模型前缀键值缓存系统

何水兵，瞿皓阳，党政

(浙江大学，中国 杭州 310027)

摘要：随着智能体应用的发展，大语言模型服务中的前缀键值（KV）缓存容量需求不断增长，逐渐超出 GPU 显存和 CPU 内存的承载能力。利用容量大、成本低的 SSD 扩展前缀缓存具有较大潜力，但其延迟较高、随机读带宽较低，直接应用会显著增加首字延迟（TTFT），难以满足实际部署需求。针对这一问题，提出了存储层级感知的大模型前缀键值缓存系统 PCache。PCache 面向显存-内存-固态硬盘（SSD）分层存储架构，通过数据布局感知的重要 KV 选择、页面级连续 KV 加载、动态 KV 重排和变序计算等技术，减少 SSD 访问与随机输入/输出（I/O）开销。相关实验验证了 PCache 可以在保持推理精度稳定的同时降低 TTFT。

关键词：大语言模型；前缀 KV 缓存；分层存储；首字延迟

Storage-Hierarchy-Aware Prefix KV Cache System for Large Language Models

HE Shuibing, QU Haoyang, DANG Zheng

(Zhejiang University, Hangzhou 310027, China)

Abstract: As the capacity demand of prefix key-value (KV) caches in large language model services for agent scenarios continues to grow, it has gradually exceeded what GPU memory and CPU memory can support. Although using high-capacity and low-cost SSDs to expand prefix caches is promising, SSDs have high access latency and low random-read bandwidth, and directly introducing them can significantly increase time to first token (TTFT), making it difficult to meet practical deployment requirements. To address this issue, this paper proposes PCache, a storage-hierarchy-aware prefix key-value (KV) cache system for large language models. On a GPU memory-CPU memory-solid state drive (SSD) hierarchy, PCache reduces SSD accesses and random input/output (I/O) overhead through data-layout-aware important KV selection, page-level continuous KV loading, dynamic KV reordering, and out-of-order computation. Experimental results show that PCache significantly reduces TTFT while maintaining stable inference accuracy, providing a technical reference for designing efficient prefix KV cache systems for long-prefix large language model serving.

Keywords: large language model; prefix KV cache; hierarchical storage; TTFT

基金项目：

浙江省自然科学基金重大项目（LD24F020012）；国家自然科学基金区域创新发展联合基金项目（U25A20423）；杭州城西科创大走廊专项发展资金项目（K20241957）

以 ChatGPT 为代表的大语言模型（LLM）在自然语言理解、代码生成、文本摘要、智能问答等任务中展现出强大的泛化能力，已成为人工智能应用领域的重要基础设施。随着模型服务从单轮问答扩展至多轮对话、检索增强生成（RAG）和智能体等复杂场景，输入侧的上下文长度不断增加，不同请求之间也更容易出现共享前缀。因此，如何减少长前缀带来的重复处理开销，逐渐成为提升大模型推理效率的关键问题。

在实际服务中，共享前缀通常源于系统提示词、用户身份和权限信息、输出格式约束、工具描述以及外部知识文档等。为避免重复计算这类前缀，现有系统通常将其对应的键值张量缓存为前缀键值缓存（Prefix KV Cache），后续请求若命中相同前缀，则直接复用缓存结果，从而减少预填充阶段的重复计算，并降低首字延迟（TTFT）。

目前,前缀键值缓存主要存储在图形处理器(GPU)显存和中央处理器(CPU)内存中,但随着缓存规模持续增长,二者在容量和成本方面的瓶颈逐渐凸显,难以支撑长前缀场景下的大规模缓存需求。相比之下,固态硬盘(SSD)具备大容量、低成本且易于部署等优势,可作为扩展前缀缓存的存储层级。然而,SSD的访问特性与前缀KV的加载需求并不匹配:SSD的访问延迟远高于显存和内存,细粒度、离散化的读取方式还会降低顺序读带宽,并且在页级管理机制下引发读放大问题,导致扩展后的缓存容量难以直接转化为TTFT收益。

针对上述问题,本文提出一种感知存储层级的大模型前缀键值缓存系统PCache。PCache面向显存-内存-SSD分层存储架构,对前缀键值数据的选择、加载、布局和计算过程进行协同优化:首先,通过感知数据布局的重要KV选择,在满足精度约束的同时减少高代价的SSD访问;其次,采用页面级连续KV加载模式,将离散访问转化为更适合SSD的顺序读取;再次,通过动态KV重排提高单次页加载的有效数据命中率,缓解读放大问题;最后,利用变序计算策略,避免重排后恢复原始顺序所带来的额外开销。通过上述设计,PCache能够在保持推理精度稳定的同时,降低前缀键值缓存的访问开销,从而提升推理性能。

1 大模型前缀缓存与分层存储

大模型推理通常通过键值缓存(KV Cache)减少生成阶段的重复计算;而在多会话推理场景下,进一步引入前缀缓存(Prefix Cache),以存储和复用不同请求中共享前缀对应的KV Cache,从而避免对该部分KV Cache的重复计算。随着可复用前缀规模持续增长,缓存系统需要借助分层存储扩展缓存容量,但不同存储介质的访问代价差异也会带来新的数据访问问题。

1.1 键值缓存

大模型每个Token的注意力输出仅依赖于其之前的Token。在自回归生成过程中,除新生成的Token外,历史Token对应的键值张量保持不变。基于这一特性,可将注意力计算中的键值张量缓存到显存中,后续生成步骤直接复用历史键值,仅计算当前Token的键值及注意力输出。这就是键值缓存^[1]。该策略将注意力层在生成阶段的重复计算转化为缓存访问,显著提升后续Token的生成速度。

1.2 前缀缓存

在大模型应用场景中,不同推理请求之间往往存在显著的上下文重叠。例如,多轮对话中的历史消息、插件调用中的系统提示词以及RAG任务中的共享文档片段都可能作为可复用前缀。前缀缓存技术将常用输入前缀对应的键值缓存预先计算并持久化存储,使后续匹配相同前缀的请求能够直接加载缓存状态,绕过重复的前缀计算过程,从而降低首字延迟,节省计算资源。随着智能体等大模型应用场景中可复用前缀的长度不断增长,现有基于内存的前缀缓存系统越来越难以满足应用的存储容量需求。

1.3 前缀缓存分层存储

为解决上述问题,业界开始探索将SSD进一步纳入存储层级,构建显存、内存、SSD三级前缀缓存存储架构。然而,显存、内存和SSD在容量、成本与访问延迟上存在明显差异:显存适于保存近期或高频访问的前缀键值,但容量有限;内存可作为显存之外的缓存层,容量更大但访问延迟更高;SSD能以较低成本保存大量前缀数据,但在随机访问和小粒度读取场景下面临较高延迟。由此,前缀键值缓存不再只是简单的存储扩容问题,而是需要在不同存储层级之间协调数据选择、加载粒度和物理布局,使容量扩展不会显著增加TTFT。

1.4 现有技术与发展趋势

现有前缀KV缓存系统主要从数据选择、缓存管理和存储硬件3个方面降低存储与访问开销。在数据选择方面,SnapKV^[2]根据注意力分布预测生成阶段的KV重要性,优先保留重要KV;IMPRESS^[3]面向多级前缀KV存储,根据KV重要性选择加载关键KV而非全部KV,以减

少存储I/O延迟；CacheGen^[4]识别并压缩非关键KV，降低缓存交换成本；CacheBlend^[5]面向RAG多轮请求，根据KV相似性选择性复用KV。上述系统能够降低逻辑读取量，但仍存在两点局限：其一，重要性评估侧重于模型贡献，缺乏对分层存储访问代价的建模；当重要KV位于SSD或分布较为离散时，仍可能产生频繁的高延迟访问；其二，Token级或KV条目级选择容易破坏SSD连续读取的特性，将数据访问转化为大量随机小读，从而降低有效读带宽。


在缓存管理方面，PagedAttention/vLLM^[6]将KV缓存组织为固定大小的块，通过虚拟页机制复用相同前缀对应的KV块，从而降低存储和计算开销；SGLang^[7]通过RadixAttention管理共享前缀，提高多请求间KV复用效率；AttentionStore^[8]将可复用KV直接卸载到SSD，并通过块级换入换出减少内存占用；华为统一缓存管理器（UCM）^[9]将前缀KV替换为可唯一寻址的缓存块，通过块索引定位并加载已有KV。这些工作有效提高了前缀KV的缓存空间利用率，但未充分考虑SSD中KV数据的物理布局。当目标KV分散在多个SSD页面时，即使每页仅有少量KV被使用，系统仍需读取完整页面，造成读放大。

在存储硬件方面，NVIDIA^[10]在本地SSD与通用共享存储之间引入面向KV缓存的G3.5闪存层，通过高速网络和专用数据处理实现跨节点KV缓存的高带宽共享；高带宽闪存（HBF）^[11]利用NAND堆叠与高带宽封装技术，在提供更大存储容量的同时，缩小闪存与高带宽内存之间的带宽差距。上述技术侧重于优化硬件性能，通过提升存储带宽来加速KV缓存访问，但尚未在数据组织层面减少无效I/O。综上，面向SSD扩展的前缀缓存系统需要从数据选择、读取粒度和物理布局3个层面进行协同优化。

2 存储层级感知的大模型前缀键值缓存系统

2.1 总体设计

针对上述问题，我们设计了 PCache，一种感知存储层级的前缀键值缓存系统。PCache 特别适用于多轮对话、知识库问答和智能体应用等通常存在大量重复上下文的大模型推理服务场景，其整体架构如图 1 所示。PCache 基于显存-内存-SSD 分层存储架构管理大模型前缀键值缓存，并围绕 SSD 访问瓶颈进行针对性布局优化。系统首先结合 KV 所在存储层级、访问代价、物理页面分布及精度约束，选择需要取回的重要 KV；随后采用页面级连续 KV 加载以减少随机读；同时根据历史访问模式动态重排 KV 布局，提高单次页面读取的有效数据密度；最后通过变序计算直接使用重排后的前缀 KV，从而避免恢复原始顺序带来的额外开销。



CPU: 中央处理器


GPU: 图形处理器

SSD: 固态硬盘

图 1 PCache 整体架构

2.2 访存代价感知的重要 KV 选择策略

PCache首先需要确定在多个存储层级中优先读取哪些重要的KV。为在减少SSD访问的同时保持推理精度，系统借助已有的Token贡献度评估结果作为精度约束，而不是将其作为唯一选择依据。我们在OPT-6.7B模型上，使用LM Evaluation Harness基准测试套件^[12]中的4个数据集，对不同KV选择方式进行了测试：一组采用注意力得分最高的 k 个Token（Top- k ），另一组随机选择Token（Rand），直至随机组的注意力得分总和超过Top- k 集合的总分。如图2所示，当保留Token数量较多时，Top- k 策略与Rand策略的推理精度相差无几；当保留Token数量较少时，Rand策略在部分任务中甚至优于Top- k 策略。该结果表明，在一定范围内，推理精度更依赖于被保留KV集合的总贡献度，而不完全取决于具体保留哪些Token。



ACC: 准确率

COPA: 因果推理选择任务

PIQA: 物理常识推理问答

RTE: 文本蕴含识别

图 2 不同 KV 选择策略精度对比

基于上述结果，PCache 在选择重要 KV 时同时考虑数据贡献度与访问代价。对于位于

SSD 上的高访问代价 KV，系统可使用多个已驻留在显存或内存中的低访问代价 KV 进行替代，只要替代后的 KV 集合仍能满足相同的精度约束即可。这样既避免了单纯按重要性排序所引发的高延迟 SSD 访问，也能优先利用分层缓存中已有的数据，从而减少对 SSD 的随机读取请求。

具体而言，PCache 将候选 Token 按物理存储位置划分为显存集合 S_{gpu} 、内存集合 S_{cpu} 和 SSD 集合 S_{ssd} ，每个集合内的 Token 按贡献度降序排列。随后，系统结合各层访存代价设置不同的候选粒度：显存和内存中的 Token 可以按多个 Token 聚合为候选单元，SSD 中的 Token 则以更严格的访存代价参与选择。最后，系统计算各候选单元的累计贡献度，并按单位访存代价收益进行贪心选择，直到满足当前请求的精度约束。其中，重要 KV 选择策略的效果与保留比例相关。当保留比例过低时，部分任务的推理精度可能出现波动。因此，PCache 将根据离线精度测试设置贡献度阈值，在访问开销和模型精度之间取得平衡。

以图 3 为例，假设用户输入的前缀为“你是一个翻译，将用户的中文转为英文”。当从前缀缓存中选择相应的重要 KV 时，传统策略会直接选取贡献度最高的 Token 集合，如“中文”、“英文”、“转为”。若其中“转为”对应的 KV 位于 SSD 上，则会触发高延迟读取。而 PCache 的访问代价感知选择策略会检查显存和内存中是否存在若干低访问代价 KV，能够共同提供相近的贡献度。若存在，系统则优先选取显存和内存中的 KV。例如，图中将“转为”替换为“你是”和“翻译”，从而在不损失贡献度的前提下减少 SSD 访问，并缩短前缀数据的取回时间。





图 3 访存代价感知的重要 KV 选择示例

2.3 页面级连续 KV 加载模式

SSD 更适合连续读取，而非大量小粒度的随机读取。若系统按 Token 粒度逐个取回前缀 KV，即便最终读取的数据总量不大，也会产生大量离散访问，从而降低 SSD 的有效带宽。针对这一问题，PCache 采用页面级连续 KV 加载模式：当系统判定需要访问某个页面中的目标 KV 时，不再仅提取页内少量 Token，而是按页连续加载相关 KV 数据。如图 4 所示，页面级连续 KV 加载将原本分散的多次随机读合并为少量顺序读，从而充分利用 SSD 的连续读带宽。同时，页内一并载入的 KV 可能提供额外的上下文贡献，使系统在满足同等精度约束的前提

下，减少所需访问的页面数量。

页面级连续 KV 加载会捎带部分非目标 KV，从而引入额外的数据读取。但 PCache 通过减少随机 I/O 次数、提高 SSD 连续读带宽，同时让额外加载的数据参与后续计算或缓存复用，从而降低整体数据取回时间。



注：t1-t8 表示不同 Token，下方数字代表当前 Token 可以提供的贡献度。


KV：键值

图 4 页面级连续 KV 加载模式和传统模式对比。

2.4 动态 KV 重排与变序计算技术

在长期运行过程中，某些前缀 KV 可能被频繁访问，但其在 SSD 中的物理位置常分散于多个页面，导致单次请求需访问大量页面，产生读放大。为解决这一问题，PCache 基于近期请求中 KV 的选中频率，动态重排页面中 KV 数据的物理布局。重排过程将高频访问 KV 迁移并紧凑排列至少量物理页，将低频 KV 集中至尾部页面。重排后，单次页加载命中有效 KV 的概率提升，系统在相同精度约束下仅需访问更少页面，从而缓解读放大，降低 SSD 读取开销。如图 5 所示，经 KV 重排后，数据加载时仅需访问页 1 和页 2，即可覆盖原本分散于 3 个页中的目标 KV。

KV 重排会带来额外的计算开销和 SSD 数据写入。为此，PCache 采取自适应的异步 KV 重排方法。首先，系统通过可配置的请求阈值动态调整重排触发频率。例如，当检测到上下文长度增加导致单次重排数据量上升时，系统会提高阈值以降低重排频率，从而减少对 SSD 的反复写入。同时，对于系统提示词、任务模板等高复用前缀，其访问热点在一定时间窗口内相对稳定，历史重排结果可被后续多个请求复用，从而摊薄数据迁移开销。当累计请求数量超过设定阈值后，KV 重排在低峰期后台异步执行，避免干扰在线推理服务的性能。



注：t1-t8表示不同Token，下方数字代表当前Token可以提供的贡献度。

KV：键值

图5 KV重排前后对比

此外，动态KV重排会改变前缀KV在物理存储中的排列顺序，因此系统需要额外维护元数据的一致性。常规做法是在元数据中维护原始位置到重排后位置的映射关系，并在数据从存储介质加载至显存后执行重排序，以恢复原始逻辑顺序。然而，这会引入额外的元数据存储、索引查询以及数据搬移开销。从注意力计算的角度来看，只要每个Token对应的K/V保持配对，且位置编码信息已包含在缓存张量中，前缀部分参与注意力计算时并不依赖其物理读取顺序。模型推理只需保证当前请求的Token能够访问其之前的所有前缀KV，而无需按原始物理顺序排列。因此，PCache在推理时直接加载并使用重排后的前缀KV，无需恢复为原始Token顺序。变序计算简化了系统元数据维护，减少了加载后的数据搬移和随机写入，从而使动态KV重排能够以较低的运行开销发挥布局优化的收益。

3 实验

为评估PCache在分层存储场景下对推理精度和首字延迟的影响，本文基于OPT-6.7B、OPT-13B和OPT-30B 3个开源模型进行实验。测试平台配备单张NVIDIA A800 GPU（80 GB显存）、128 GB内存和2 TB Intel SSD，SSD连续读带宽实测约为5 GB/s。实验中，分配10 GB显存和32 GB内存用于前缀缓存，其余前缀KV存储于SSD，构成GPU显存-CPU内存-SSD三级缓存架构。为模拟实际大模型服务中系统提示词等前缀在不同请求间重复使用的场景，实验选用LM Evaluation Harness基准测试套件^[12]中的PIQA、RTE、COPA和OpenBookQA四个数据集，参照现有工作^[13]，在每个请求前添加2~10个few-shot示例作为共享前缀，并通过正态分布设定不同前缀的复用频率，以构建具有非均匀访问热度的前缀缓存负载。


本文将PCache与以下3个基准系统进行对比：1）重计算（ReComp）：不使用前缀缓存，每个请求到达时重新计算全部前缀Token的键值，作为精度无损但延迟最高的基线；2）注意力存储系统（AS）：基于FlexGen复现AttentionStore^[8]，采用全量异步存储与加载键值缓存。为保证公平性，本文为其配置了与PCache相同的GPU显存-CPU内存-SSD三级缓存架构，并禁用了其依赖先来先服务（FCFS）调度的特定预取优化；（3）AS+H2O：在AS基础上集成H2O^[14]，该基线先加载前缀的全量K向量以计算Token贡献度，再加载被选中的V向量以完成后续推理。

实验从模型推理精度和TTFT两个维度评估PCache性能，分别用于衡量分层缓存优化对模型输出质量和前缀KV取回延迟的影响。

3.1 模型推理精度

本节的测试遵循现有工作^[13-14]，采用回答正确率（ACC）作为核心评价指标，并在 5% 至 50% 范围内调整 KV 保留比例，以探究不同压缩比例下 PCache 的数据选择与加载机制是否会影响模型推理精度。

图 6 展示了各系统在不同 KV 保留比例下对模型推理精度的影响。由于重计算与 AS 在推理精度上无显著差异，且 PCache 主要改变数据调度与物理访问方式，并未修改模型计算逻辑，因此图 6 以 ReComp 代表重计算和 AS 的重合结果，并展示了 AS+H2O 与 PCache 的精度曲线。实验结果显示，PCache 在所有测试模型和数据集上的推理精度与对比对象基本持平。与重计算基准及 AS+H2O 相比，PCache 的精度损失均控制在 1% 以内。这表明，PCache 的访存代价感知重要 KV 选择策略与页面级连续 KV 加载机制，能够在减少 SSD 访问开销的同时，有效保留模型输出所需的关键上下文信息。



ACC: 准确率

AS: 注意力存储系统

COPA: 因果推理选择任务

H2O: 重击者选择方法


PIQA: 物理常识推理问答

RTE: 文本蕴含识别

图 6 不同数据集下模型推理精度对比

3.2 模型推理延迟

为在精度与延迟之间取得合理平衡，基于图6的精度结果，延迟实验中将COPA数据集的 KV 保留比例设为 50%，其余数据集设为 25%。在此配置下，PCache 带来的精度损失不足 0.2%，处于实际应用可接受的范围内。图 7 展示了各系统的平均 TTFT 对比。PCache 相对于重计算基准实现了 2.18 倍至 3.84 倍的 TTFT 加速。即便与每组对比中的最优基线相比，PCache 仍能获得最高约 46% 的额外性能提升。



AS: 注意力存储系统
COPA: 因果推理选择任务
H2O: 重击者选择方法
OPT: 开放预训练 Transformer 模型
PIQA: 物理常识推理问答
RTE: 文本蕴含识别
TTFT: 首字延迟

图 7 不同数据集下模型推理 TTFT 对比

4 结束语

随着大模型服务向长上下文和高复用场景的持续演进，前缀KV缓存已成为影响系统成本与服务首字延迟的关键资源。本文提出存储层级感知的大模型前缀键值缓存系统PCache，通过重要KV选择、页面级连续KV加载、动态KV重排及变序计算等机制，有效降低SSD扩展带来的随机访问开销。实验结果表明，PCache能够在保持推理精度稳定的同时，显著降低TTFT延迟。这说明，SSD扩展前缀缓存的关键不仅在于增加存储容量，还需要围绕访问粒度、物理布局与计算过程进行协同优化。

参考文献

- [1] Pope R, Douglas S, Chowdhery A, et al. Efficiently scaling transformer inference [J]. Proceedings of machine learning and systems, 2023, 5: 606-624
- [2] Li Y H, Huang Y B, Yang B W, et al. SnapKV: LLM knows what you are looking for before generation [C]//Proceedings of Advances in Neural Information Processing Systems 37. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2024: 22947-22970. DOI: 10.52202/079017-0722
- [3] Chen W, He S, Qu H, et al. IMPRESS: an importance-informed multi-tier prefix KV storage system for large language model inference [C]//Proceedings of the 23rd USENIX Conference on File and Storage Technologies. 2025: 187-201
- [4] Liu Y H, Li H C, Cheng Y H, et al. CacheGen: KV cache compression and streaming for fast large language model serving [C]//Proceedings of the ACM SIGCOMM 2024 Conference.

- ACM, 2024: 38-56. DOI: 10.1145/3651890.3672274
- [5] Yao J Y, Li H C, Liu Y H, et al. CacheBlend: fast large language model serving for RAG with cached knowledge fusion [C]//Proceedings of the Twentieth European Conference on Computer Systems. ACM, 2025: 94-109. DOI: 10.1145/3689031.3696098
- [6] Kwon W, Li Z H, Zhuang S Y, et al. Efficient memory management for large language model serving with PagedAttention [C]//Proceedings of the 29th Symposium on Operating Systems Principles. ACM, 2023: 611-626. DOI: 10.1145/3600006.3613165
- [7] Zheng L M, Yin L S, Xie Z Q, et al. SGLang: efficient execution of structured language model programs [PP/OL]. arXiv (2023-12-12)[2026-05-25]. <https://arxiv.org/abs/2312.07104>
- [8] Gao B, He Z, Sharma P, et al. Cost-efficient large language model serving for multi-turn conversations with CachedAttention [PP/OL]. arXiv (2024-03-23)[2026-05-25]. <https://arxiv.org/abs/2403.19708>
- [9] ModelEngine-Group. Unified cache management [EB/OL]. (2026-02-10)[2026-05-25]. <https://github.com/ModelEngine-Group/unified-cache-management>
- [10] Anschel M, Zilberstein E, Duer O, et al. Introducing NVIDIA BlueField-4-powered CMX context memory storage platform for the next frontier of AI [EB/OL]. (2026-03-26)[2026-05-25]. <https://developer.nvidia.com/blog/introducing-nvidia-bluefield-4-powered-inference-context-memory-storage-platform-for-the-next-frontier-of-ai>
- [11] Sandisk. High bandwidth flash (HBF) fact sheet [EB/OL]. [2026-05-25]. https://documents.sandisk.com/content/dam/asset-library/en_us/assets/public/sandisk/collateral/company/Sandisk-HBF-Fact-Sheet.pdf
- [12] Gao L, Tow J, Biderman S, et al. A framework for few-shot language model evaluation [EB/OL]. [2026-05-25]. <https://zenodo.org/records/12608602>
- [13] Lee W, Lee J, Seo J, et al. InfiniGen: efficient generative inference of large language models with dynamic KV cache management [C]//Proceedings of the 18th USENIX Symposium on Operating Systems Design and Implementation. 2024: 155-172
- [14] Zhang Z Y, Sheng Y, Zhou T Y, et al. H2O: heavy-hitter oracle for efficient generative inference of large language models [C]//Proceedings of Advances in Neural Information Processing Systems 36. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023: 34661-34710. DOI: 10.52202/075280-1506

作者简介

何水兵，浙江大学计算机科学与技术学院特聘教授、博士生导师；主要从事智能计算、存储系统、计算机体系结构等方面的研究；主持国家级和省部级项目 10 余项；获 2024 年浙江省科技进步奖一等奖、2023 年浙江省科技进步奖一等奖；发表论文 100 余篇。

瞿皓阳，浙江大学在读硕士研究生；主要研究方向为大语言模型推理优化。

党政，浙江大学在读博士研究生；主要研究方向为智能计算、异构内存管理等。